

IQR 정규화를 이용한 SSD 기반 도로장애물 탐지 모델 경량화 방법

*고준하, *이동준, *최다훈, 구광현, 김현

서울과학기술대학교 전기정보공학과 전기정보기술연구소

e-mail : {wnsgk1021, 0622dong, dahun926, kookh0414, hyunkim}@seoultech.ac.kr

Lightweight Method for Road Obstacle Detection Model Based on SSD Using IQR Normalization

*Jun Ha Ko, *Dong Jun Lee, *Da Hun Choi, Kwang Hyun Koo, Hyun Kim

Depart. of EIE and Research Center for Electrical and Information Technology,
Seoul National University of Science and Technology

Abstract

Recently, advancements in deep learning have significantly improved object detection accuracy, crucial for autonomous vehicles. However, these models often face deployment challenges on edge platforms due to their large sizes and high computational demands, resulting in latency issues. To address this issue, compression techniques such as pruning and quantization have been proposed. This paper proposes a compression technique for real-time road obstacle detection on edge platforms, using SSD model. We applied the interquartile range (IQR) method to reduce quantization errors. Experimental results show that our method improves accuracy from 0.62% to 41.36% compared to integer quantization at various precisions.

I. 서론

최근 convolutional neural networks (CNNs)의 비약적인 발전과 함께 객체 탐지를 위한 네트워크가 우수한 정확도를 달성하였으며, 자율주행 자동차의 딥러닝 기술 활용이 주목을 받고 있다[1]. 자율주행 자동차의 안정성과 신뢰성을 확보하기 위해 포트홀과 같은 도로 장애물 탐지의 중요성이 대두되고 있다. 최근 연구되고 있는 객체탐지 모델은 우수한 정확도를 성취하기 위하여 모델의 크기를 키우거나 연산량을 늘리는 방향으로 연구되어 왔다[2]. 하지만 이러한 방법은 자율주행 시스템과 같은 엣지 플랫폼에서 배포가 어려울 뿐만 아니라 긴 지연시간으로 인해

실시간 탐지에 어려움이 발생하여 도로 장애물을 탐지하는데 어려움이 있다[3]. 이를 해결하기 위해 프루닝[4], 양자화[5] 같이 다양한 경량화 기법이 제안되고 많은 연구가 이루어지고 있다. 그 중 양자화는 CNN에서 가장 많은 연산량을 차지하는 컨볼루션 연산을 효율적으로 연산할 수 있으며 모델 크기를 효과적으로 줄일 수 있다.

본 논문은 엣지 플랫폼에서 도로 장애물의 실시간 탐지를 위한 경량화 기법을 제안한다. 경량화 된 네트워크인 MobileNetV1 [6]을 backbone으로 사용한 SSD[7] 모델의 구조적 특징을 고려한 경량화 기법을 적용하였다. 또한, 가중치의 분포도 특징을 고려한 interquartile range (IQR)방법을 사용하여 양자화에러를 줄일 수 있었다. 실험 결과, 가중치와 활성화를 모두 4-bit로 양자화 하였을 때, 제안 경량화 방법은 일반적인 정수 양자화 대비 최대 41.36% 만큼 우수한 정확도를 성취할 수 있었다.

II. 배경

2.1 MobileNet V1 SSD lite

MobileNetV1 SSD lite는 객체 탐지를 위해 최적화된 경량 모델로, 효율성과 성능의 균형을 맞추기 위해 설계되었다. MobileNetV1은 depthwise separable convolution(DSC)을 주요 구성 요소로 사용하는데, 이는 표준 컨볼루션 연산보다 훨씬 적은 연산량과 파라미터로 유사한 성능을 제공한다. 이러한 구조는 모델의 크기와 연산량을 크게 줄임으로써, 모바일 및 엣지 디바이스에서의 효율적인 배포를 가능하게 한다.

SSD lite는 Single Shot Multibox Detector (SSD)의 변형으로, 객체 탐지를 위한 구조 중 하나다. SSD lite는 SSD의 기본 구조를 유지하면서도 더 적은 연산으로 동일 작업을 수행하기 위해 DSC를 활용한다.




그림 1. MobileNetV1 SSD lite 구조

2.2 양자화(Quantization)

양자화는 컨볼루션 연산에서 가중치와 입력 데이터를 저장밀도 표현으로 변환하여 메모리 사용량을 줄이고, 연산 속도를 향상시키는 경량화 기술이다. 식(1)은 스케일링 팩터를 구하는 과정으로 $\max_val$, $\min_val$ 은 각각 가중치 또는 활성화 데이터의 최대값, 최소값을 나타낸다. 식(2)에서 $Q(x)$ 는 실제 양자화를 구현하는 함수로, 입력 x 를 스케일링 팩터 계산을 통해 정수 범위 내로 매핑한다. 여기서 clamp 는 임계값을 정의해주는 함수이다. 양자화된 모델은 기존의 부동소수점 연산을 정수 연산으로 대체하여, 하드웨어에서 연산을 효율적으로 처리할 수 있다.

$$s = \frac{2^b - 1}{\max_val - \min_val} \quad (1)$$

$$Q(x) = \text{clamp}(\text{round}(s * x), -2^{b-1}, 2^{b-1} - 1) \quad (2)$$

III. 구현

3.1 모델 구조를 고려한 양자화 부호 설정

양자화로 인한 정확도 하락을 최소화하기 위해 모델 구조에 따라 특징맵의 양자화 부호를 설정해야한다. 모델에서 음수 값을 모두 0으로 처리하는 ReLU를 사용하기 때문에 특징맵 양자화는 unsigned 정수 양자화로 구현하였다. 이때 첫 번째 레이어의 입력은 전처리 과정에서 정규화를 적용하기 때문에 음수 값이 포함되어있어 signed 정수 양자화를 진행한다. 또한 extra와 regression header, classification header에서 convolution 레이어 이후 ReLU를 통과하지 않고 한 번 더 convolution 레이어를 거치는 경우에도 signed int 양자화를 적용해 구현하였다.

3.2 Interquartile Range정규화 기법

IQR 정규화는 데이터의 중앙 50%에 해당하는 값들의 범위, 즉 제1사분위수 (Q1)와 제3사분위수 (Q3) 사이의 범위를 이용하는 통계적 기법이다. 이 방법은 다른 정규화 방법 대비 outlier의 영향을 크게 받지 않기 때문에 정규화로 인한 에러가 적다.

식(3)는 IQR을 구하는 과정으로 Q1은 데이터의 하위 25%를 초과하는 최소값 (제1사분위수), Q3는 데이터의 상위 25%를 미만인 최대값 (제3사분위수)이다. x_{norm} 으로 표현된 정규화된 값은 식(4)로 표현된다. 데이터의 중앙값 (median)을 기준으로 데이터를 IQR로 나누어 분포도를 스케일링한다. IQR 방법을 통해 outlier로 인한 에러를 효과적으로 줄일 수 있다.

표 1. 양자화 precision 에 따른 SSD 실험 결과

Method	W/A precision	Accuracy (%)	Drop. (%)
Baseline	32/32	83.21	—
Quant	8/8	83.42	-0.21
Ours	8/8	84.28	-1.07
Quant	4/8	81.69	1.52
Ours	4/8	82.31	0.90
Quant	4/4	36.84	46.37
Ours	4/4	78.20	5.01

$$IQR = Q3 - Q1 \quad (3)$$

$$x_{norm} = \frac{x - \text{median}}{IQR} \quad (4)$$

IV. 실험 결과

4.1 실험 환경

본 논문은 RTX 2080 Ti 하드웨어 환경에서 PyTorch 프레임워크 기반 MobileNet V1 SSD lite 모델과 Pascal VOC format의 Custom 데이터셋을 사용하여 이루어졌다. 양자화는 post-training quantization을 적용하였으며 가중치와 특징맵에 다양한 정밀도를 적용하여 실험을 진행하였다.

4.2 실험 결과 분석

표 1에서 W/A는 각각 가중치와 특징맵을 의미하며, Quant는 정규화를 적용하지 않은 일반적인 양자화 방법이다. 실험결과 8/8 양자화 실험에서 제안방법은 baseline 대비 1.07% 정확도가 향상하였다. 4/8 양자화 실험에서 baseline 대비 0.90% 성능하락이 존재했으나 Quant 대비 0.62% 높은 성능을 성취할 수 있었다. 특히 activation precision을 4-bit로 조정했을 때 Quant는 심각한 성능하락이 발생했으나 제안 방법은 Quant 보다 훨씬 더 적은 정확도 하락을 달성하였다. 이는 IQR 정규화가 이상치에 영향을 적게 받으며 저정밀도 양자화를 적용해도 성능을 유지하는데 적합한 방법임을 알 수 있다.

V. 결론 및 향후 연구 방향

본 논문은 도로 장애물 탐지를 위한 경량화된 인공지능 모델을 엣지 디바이스에서 구현할 수 있도록 정규화 기법 기반의 양자화를 제시한다. MobileNet v1 SSD lite 모델을 사용하여 양자화와 IQR 정규화 기법을 적용함으로써, 리소스가 제한된 환경에서도 인공지능 모델의 성능을 유지하면서 구현할 수 있도록 하였다. 이 과정에서 clipping range를 조정하여 모델 구조에 맞게 최적화하고 IQR 정규화를 통해 가중치 분포를 정규화하여 양자화 시 발생할 수 있는 성능 저하를 최소화하였다. 특히, IQR 정규화가 모델의 일반화 능력을 증가시키고 outlier의 영향을 줄임으로써 성능 저하

를 상당 부분 방지할 수 있음을 보였다. 이는 엣지 디바이스에서 AI 모델을 구현할 때 중요한 고려사항이 될 수 있다. 향후 연구에서는 검증된 다양한 데이터셋과 모델에서 실험을 진행하여 해당 방법의 범용성과 실용성을 검증할 수 있을 것으로 기대된다.

감사의 글

이 논문은 2024년도 정부(과학기술정보통신부)의 재원으로 정보통신기획평가원의 지원(No.2020-0-01304, 모바일 자가 학습 가능 채귀 뉴럴 네트워크 프로세서 기술개발)을 받아 수행된 연구결과와 과학기술정보통신부 및 정보통신기획평가원의 대학ICT연구센터육성지원사업(IITP-2024-RS-202200156295)의 연구결과와 교육부와 한국연구재단의 재원으로 지원을 받아 수행된 3단계 산학협력 선도대학 육성사업(LINC 3.0)의 연구결과입니다.

참고문헌

- [1] J. Choi, D. Chun, H. Kim, and H.-J. Lee, "Gaussian yolov3: An accurate and fast object detector using localization uncertainty for autonomous driving," in *Proceedings of the IEEE/CVF International Conference on Computer Vision, 2019*, pp. 502-511
- [2] A. Bochkovskiy, C.-Y. Wang, and H.-Y. M. Liao, "Yolov4: Optimal speed and accuracy of object detection," *arXiv preprint arXiv:2004.10934*, 2020.
- [3] B. Liu, Y. Lv, Y. Gu, and W. Lv, "Implementation of a lightweight semantic segmentation algorithm in road obstacle detection," *Sensors*, vol. 20, no. 24, p. 7089, 2020
- [4] N. J. Kim and H. Kim, "Fp-agl: Filter pruning with adaptive gradient learning for accelerating deep convolutional neural networks," *IEEE Transactions on Multimedia*, 2022.
- [5] S. Kim and H. Kim, "Zero-centered fixed-point quantization with iterative retraining for deep convolutional neural network-based object detectors," *IEEE Access*, vol. 9, pp. 20 828-20 839, 2021.
- [6] A. G. Howard, M. Zhu, B. Chen, D. Kalenichenko, W. Wang, T. Weyand, M. Andreetto, and H. Adam, "Mobilenets: Efficient convolutional neural networks for mobile vision applications," *arXiv preprint arXiv:1704.04861*, 2017.
- [7] W. Liu, D. Anguelov, D. Erhan, C. Szegedy, S. Reed, C.-Y. Fu, and A. C. Berg, "Ssd: Single shot multibox detector," in *Computer Vision-ECCV 2016: 14th European Conference, Amsterdam, The Netherlands, October 11-14, 2016, Proceedings, Part I 14*. Springer, 2016, pp. 21-37.