

IQR 정규화를 이용한 SSD 기반 도로장애물 탐지 모델 경량화방법

고준하, 이동준, 최다훈, 구광현, 김현
서울과학기술대학교 전기정보공학과 전기정보기술연구소



Motivation

- 최근 convolutional neural networks(CNNs)이 우수한 정확도를 성취하기 위하여 **모델의 크기**를 키우거나 **연산량**을 늘리는 방향으로 연구되어 왔음
- 자율주행 시스템과 같은 엣지 플랫폼에서 **연산처리**가 어렵고, **긴 지연 시간**이 발생하므로 프루닝, 양자화 같은 **경량화 기법**을 적용해야 함
- 기존 정규화 방법에서 W/A int4/int4 양자화를 적용하는 경우 precision이 46.37%의 큰 폭으로 떨어져 outlier에 영향

Background

- MobileNet V1 SSD lite
 - MobileNetV1은depthwise separable convolution(DSC)을 사용하는데, 이는 표준 컨볼루션 연산보다 훨씬 **적은 연산량과 파라미터로 유사한 성능**을 제공함
 - SSD lite는 Single Shot Multibox Detector(SSD)의 변형으로, 기본 구조를 유지하면서도 DSC를 활용함




Fig. 1. MobileNetV1 SSD lite 구조

Proposed Method

Interquartile Range(IQR) 정규화

- IQR 정규화는 일반적인 정규화 방법 대비 **outlier의 영향**을 크게 받지 않기 때문에 정규화로 인한 **에러가 적음**
- 양자화 이전 데이터에 IQR 정규화 기법을 적용한 후 round, clipping 적용하여 구현
 - Normal Regularization:** $x_{norm} = \frac{x-\mu}{\sigma}$
 - x_{norm} : normalized value of x , x : original data value, μ : mean of the data, σ : standard deviation of the data
 - IQR Regularization:** $IQR = Q3 - Q1$, $x_{norm} = \frac{x-median}{IQR}$
 - IQR : interquartile range, $Q1$: first quartile(25%), $Q3$: third quartile(75%)




Fig. 2. IQR 정규화

Experimental Results

- 실험 환경: MobileNetV1 SSD lite model, Pascal VOC Custom Dataset
- Baseline:** 양자화를 적용하지 않은 일반적인 추론 결과
- Quant:** 일반적인 정규화 방법을 이용한 양자화 방법
- Ours:** 양자화 이전 데이터에 IQR 정규화를 적용한 후 양자화 한 방법
- 전반적으로 IQR정규화 적용 시 Baseline 대비 **높은 정확도를 달성함**

Method	W/A Precision	Accuracy (%)	Drop (%)
Baseline	32/32	83.21	-
Quant	8/8	83.42	-0.21
Ours	8/8	84.28	-1.07
Quant	4/8	81.69	1.52
Ours	4/8	82.31	0.90
Quant	4/4	36.84	46.37
Ours	4/4	78.20	5.01

Table 1. 양자화 precision에 따른 SSD 실험 결과