

Optimization Technique for Mobilenet V1 SSD Lite Using Inter Quartile Range -Based Outlier Detection

Dongjun Lee, Seungil Lee, and Hyun Kim

Department of Electrical and Information Engineering, Research Center for Electrical and Information Technology, Seoul National University of Science and Technology, Korea

최근 convolutional neural network (CNN)의 비약적인 발전은 객체 탐지 모델의 성능을 크게 향상시키며 다양한 분야에서의 활용 가능성을 높이고 있다. 그러나 정확도를 높이기 위해 모델의 크기와 연산량을 증가시키는 접근이 주를 이루면서 이들을 엣지/모바일 디바이스에 효율적으로 적용하기 어렵다는 문제가 대두되고 있다. 이를 해결하기 위해 경량 네트워크인 MobileNet [1]과 같은 구조가 객체 탐지 모델의 backbone으로 사용되고 있지만 엣지 환경에서의 실시간 저전력 처리를 위해서는 추가적인 경량화 기법, 특히 양자화의 도입이 필수적이다. 그러나 MobileNet의 가중치 분포에는 그림 1과 같이 다수의 outlier가 존재하여 일반적인 양자화 기법으로는 높은 정확도를 유지하기 어렵다. 따라서 본 논문에서는 MobileNet V1을 backbone으로 사용하는 SSD 모델의 구조적 특징을 고려한 양자화 기법을 제안한다. 그림 2와 같이 가중치의 outlier 처리를 위해 inter quartile range(IQR) 방법을 적용하여 가중치를 outlier와 non-outlier로 구분하고, non-outlier에만 선택적으로 더 낮은 precision의 양자화를 적용함으로써 정확도 하락을 최소화한다. 4개 클래스를 가지는 커스텀 데이터셋에서의 실험 결과, 제안 방법을 통해 가중치와 활성화를 각각 4-bit, 8-bit로 양자화했을 때 FP32 대비 1% 수준의 정확도 저하를 성취하여 일반적인 정수 양자화로 가중치와 활성화를 각각 4-bit와 8-bit로 양자화한 경우 대비 54.33% 만큼 높은 정확도를 달성하였다.




그림 1. MobileNet 기반 SSD의 가중치 분포





그림 2. IQR 방법

Acknowledgments This work was partly supported by the Ministry of Science and ICT(MIST) and Institute of Information & communications Technology Planning & Evaluation (IITP) grant funded by the Korea government(MOE) (No.2024-0-00085, Artificial Intelligence (AI) Semiconductor Human Resource Development) and National Research Foundation of Korea(NRF) grant funded by the Korea government(MSIT) (No. 2022R1F1A1062786).

References [1] A. G. Howard, M. Zhu, B. Chen, D. Kalenichenko, W. Wang, T. Weyand, M. Andreetto, H. Adam, "Mobilenets: Efficient convolutional neural networks for mobile vision applications," arXiv preprint arXiv:1704.04861 (2017).