

Optimization Technique for Mobilenet V1 SSD Lite Using Inter Quartile Range -Based Outlier Detection



Dongjun Lee, Seungil Lee, and Hyun Kim
Seoul National University of Science and Technology

Motivation

- 최근 convolutional neural network(CNN)의 비약적인 발전은 객체 탐지 **모델의 성능을 향상**시키며 다양한 분야에서의 활용 가능성을 높임
- 정확도를 높이는 과정에서 **모델의 크기**와 **연산량이 크게 증가**하여, 엣지 및 모바일 디바이스에서 모델을 효율적으로 활용하기 어려움
- Mobilenet V1/V2와 같은 **경량 네트워크** 구조가 객체 탐지 모델의 **backbone**으로 사용되고 있으나 엣지 환경에서의 실시간 처리를 위해서는 추가적인 경량화, 특히 **양자화**의 도입이 **필수적**
- Mobilenet은 weight의 **outlier**로 인해 양자화 적용 시 **성능 하락**

Background

- MobileNet V1 SSD lite**
 - MobileNetV1**은 depthwise separable convolution(DSC)을 사용하며, 이는 기존 standard convolution 연산보다 훨씬 **적은 연산량과 파라미터**로 유사한 성능을 제공함
 - SSD lite**는 Single Shot Multibox Detector(SSD)의 변형으로, 기본 구조를 유지하면서도 **DSC을 활용**함




Fig. 1. MobileNetV1 SSD lite 구조

Proposed Method

Outlier Detection Method

- Interquartile Range(IQR)**를 사용해 데이터를 **Outlier**와 **Non-Outlier** 두 가지로 구분
- 양자화 적용 시 **Outlier**는 **FP32**으로 유지하고 **Non-Outlier**는 **INT N-bit**으로 양자화
- Q1**: first quartile(25%), **Q3**: third quartile(75%), **IQR** = $Q3 - Q1$
- Lower Bound** = $Q1 - k \times IQR$, **Upper Bound** = $Q3 + k \times IQR$
- Outlier**: $x < \text{Lower Bound}$ or $x > \text{Upper Bound}$
- Non-Outlier**: $\text{Lower Bound} < x < \text{Upper Bound}$
 - k : outlier 탐지 민감도를 조정하는 scaling factor
- Outlier의 영향**을 **최소화**하면서도 대부분의 데이터를 **효율적으로 양자화**




Fig. 2. Interquartile Range(IQR)

Experimental Results

- 실험 환경**: NVIDIA RTX 2080 Ti x 8을 사용해 학습, MobilenetV1 SSD lite에서 Pascal VOC Custom Dataset 평가
- Baseline**: 양자화 적용하지 않은 일반적인 추론 결과
- Quant**: 일반적인 min/max 양자화 방법
- Ours**: IQR을 활용하여 outlier 탐지 후 양자화 한 방법
- Ours 중 **W/A 4/8**로 양자화 했을 때 **Baseline 대비 1.02% 정확도 저하**로 일반적인 정수 양자화 **Quant 대비 54.33% 만큼 높은 정확도** 달성
- Mobilenet의 **outlier를 고려**하여 **양자화 오차를 줄이는 방법** 제안

k	Method	Weight Precision	Activation Precision	Accuracy (%)	Drop (%)
1.5	Baseline	FP32	FP32	59.45	-
	Quant	INT8	INT8	59.36	0.08
	Ours	INT8+FP32	INT8	59.312	0.13
	Quant	INT4	INT8	40.94	55.35
	Ours	INT4+FP32	INT8	58.42	1.02
	Quant	INT4	INT4	0.45	59.40
	Ours	INT4+FP32	INT4	3.51	55.93

Table 1. 양자화 precision에 따른 SSD 실험 결과

