

하드웨어 친화적인 Power-of-Two 스케일 팩터 기반 MobilenetV1 SSD Lite 양자화

이동준, 강범진, 김현

서울과학기술대학교 전기정보공학과 전기정보기술연구소

e-mail : {dj.lee, beomjin, hyunkim}@seoultech.ac.kr

Hardware-Friendly Quantization of MobileNetV1 SSD Lite Using Power-of-Two Scale Factors

Dongjun Lee, Beomjin Kang, Hyun Kim

Depart. of EIE and Research Center for Electrical and Information Technology,
Seoul National University of Science and Technology

Abstract

As convolutional neural networks (CNNs) continue to progress in computer vision, their high computational cost poses a challenge for deployment on edge devices. To address this, we propose a fused quantization technique for MobileNetV1 SSD Lite that integrates consecutive quantization steps into a single scale factor, approximated using a power-of-two (PoT) format for shift-based implementation. To mitigate the limited precision of single PoT terms, we adopt an additive PoT (APoT) approach that combines multiple terms. Experiments on the Pascal VOC dataset demonstrate that our method achieves a marginal 0.74% drop in mAP compared to the full-precision model, while surpassing uniform and single-PoT quantization in both accuracy and hardware efficiency.

I. 서론

최근, convolutional neural networks(CNNs)는 컴퓨터 비전 분야에서 우수한 성능을 달성하였다 [1]. 그러나, 이러한 성능 향상은 모델의 크기와 연산량의 증가를 동반하며, 이는 높은 정확도뿐 아니라 저전력 실시간 추론이 중요한 자율 주행, 산업용 로봇 등의 엣지 디바이스 배포에 큰 제약이 된다 [2].

이러한 제약을 해결하기 위해 추론 정확도는 유지하면서 모델의 크기와 연산량을 줄이는 경량화 연구가 주목받고 있다. 그중, 양자화 기법은 모델의 파라미터와 입력 데이터를 낮은 정밀도 정수로 변환하여 모델의 크기를 줄이고, 정수 연산을 기반으로 추론 가속을 가능하게 한다 [3].

본 논문에서는 대표적인 객체 탐지 모델인 MobileNetV1 SSD Lite [4]의 효율적인 엣지 디바이스 배포를 위해, 하드웨어 친화적인 fused 양자화 기법을 제안한다. 구체적으로, 연속된 레이어 간 역양자화, 양자화 연산을 통합하여 추가적인 양자화 연산 비용을 최소화한다. 또한, 스케일 팩터를 2^k 형태로 표현하는 Power-of-Two(PoT) 근사화를 적용하여 하드웨어 친화적인 shift 연산만으로 양자화를 구현한다 [5]. 그러나, 단일 PoT 항으로 근사화했을 때 표현 가능한 스케일 팩터의 resolution이 제한되는 한계점이 존재한다 [6]. 이에 따라, 여러 개의 PoT 항들의 조합으로 스케일 팩터를 표현하는 Additive Power-of-Two (APoT) 기법을 차용하여 보완하였다 [6].

우리는 제안된 방법을 Pascal VOC 데이터셋에서 MobileNetV1 SSD Lite 모델에 적용하여 객체 탐지 성능을 평가하였으며, 0.74%의 mean average precision (mAP) 하락만으로 하드웨어 친화적인 양자화 연산을 구현하였다.

II. 배경

2.1 양자화

양자화는 CNN 모델의 크기를 줄이기 위한 대표적인 경량화 기법이다. 일반적으로 사용되는 uniform 양자화에서, 임의의 부동 소수점 입력 x 를 정수 값 $\hat{x}$ 으로 변환하는 과정은 다음과 같다:

$$s = \frac{R_{max}}{2^{b-1} - 1} \quad (1)$$

$$\hat{x} = clip\left(\left\lfloor \frac{x}{s} \right\rfloor, -2^{b-1}, 2^{b-1} - 1\right) \quad (2)$$

여기서 $\lfloor \cdot \rfloor$ 는 반올림, b 는 양자화 비트 수, R_{max} 는 x 의 최대값을 나타낸다. s 는 스케일 팩터로, 데이터의 범위에 따라 calibration을 통해 결정된다. 이후, 정수 값을 실수 범위로 복원하기 위한 역양자화는 다음과 같은 식으로 표현할 수 있다:

$$x_{dq} = \hat{x} \cdot s \quad (3)$$

(1)–(3)에서 볼 수 있듯이, 양자화–역양자화 연산은 부동 소수점과 정수 도메인 간의 변환 과정에서 추가적인 부동 소수점 곱셈 연산을 야기한다. 이러한 연산은 실제 하드웨어 구현 시 전력 소모, 연산 지연 등의 문제를 초래하며, 이는 엣지 디바이스 배포에 큰 제약이 될 수 있다 [7].

2.2 PoT 기반 양자화

양자화 과정에서 발생하는 부동 소수점 연산 비용을 줄이기 위해, PoT 기반 양자화 기법이 연구되었다. PoT 기반 양자화는 스케일 팩터를 2^k 형태로 표현하여, 부동 소수점 곱셈 연산을 하드웨어 친화적인 shift 연산으로 대체한다. 그러나 양자화 수준이 조밀하게 분포된 영역에만 집중되는 rigid resolution 문제가 발생하여, 데이터 분포를 정확히 표현하지 못하는 단점이 있다 [6]. 이러한 문제를 완화하기 위해 여러 개의 PoT 항을 조합하여 스케일 팩터를 근사하는 Additive Power-of-Two (APoT) 기법이 제안되었다 [6]. 본 논문에서는 APoT 기법을 fused 양자화에 적용하여, 하드웨어 친화적이면서도 정확도 저하를 최소화하는 방법을 제안한다.

III. 구현

본 논문에서는 하드웨어 친화적인 fused 양자화를 적용하며, 스케일 팩터에 대해 APoT 기반 근사를 적용하여 resolution을 보존하면서도 shift-add 기반의 효율적인 연산이 가능하도록 한다.

3.1 Fused 양자화

양자화가 적용된 정수 입력 $\hat{x}$ 와 파라미터 $\hat{w}$ 의 convolution 연산과 역양자화 연산은 다음과 같이 수행된다:

$$y = s_x s_w (\hat{x} * \hat{w}) \quad (4)$$

(4)에서 s_x , s_w 는 weight, activation 스케일 팩터를, $\hat{x} * \hat{w}$ 는 정수 기반의 convolution 연산을 나타낸다. 출력 y 는 양자화를 통해 정수로 변환되며 다음 convolution 레이어의 입력이 된다. 이때, y 의 양자화 과정은 다음과 같다:

$$\hat{y} = clip\left(\left\lfloor \frac{s_x s_w (\hat{x} * \hat{w})}{s_y} \right\rfloor, -2^{b-1}, 2^{b-1} - 1\right) \quad (5)$$

(5)에서 s_y 는 y 의 스케일 팩터를 나타내며, 이를 통해 양자화된 출력 $\hat{y}$ 를 얻는다. 이 과정에서, 다음과 같이 스케일 팩터를 fusing 할 수 있다:

$$\hat{y} = clip\left(\left\lfloor s_f (\hat{x} * \hat{w}) \right\rfloor, -2^{b-1}, 2^{b-1} - 1\right) \quad (6)$$

$$where s_f = \frac{s_x s_w}{s_y}$$

결국, fused 양자화는 연속되는 역양자화–양자화 과정을 통합하여 추가적인 연산 비용을 최소화시킬 수 있다.

3.2 APoT 기반 fused 양자화

(6)에서, 스케일 팩터는 부동 소수점 값으로 표현된다. 즉, 하드웨어 구현 시 추가적인 부동 소수점 곱셈 연산을 필요로 하고, 이는 추론 지연과 전력 소모를 증가시키는 원인이 된다. 이를 해결하기 위해 스케일 팩터를 PoT 형태로 근사화한 양자화는 다음과 같다:

$$\hat{y} \approx clip\left(\left\lfloor \hat{s}_f (\hat{x} * \hat{w}) \right\rfloor, -2^{b-1}, 2^{b-1} - 1\right) \quad (7)$$

$$= clip\left(\left\lfloor (\hat{x} * \hat{w}) \gg k \right\rfloor, -2^{b-1}, 2^{b-1} - 1\right)$$

$$where \hat{s}_f = 2^k$$

(7)의 기본적인 PoT 근사화는, 부동 소수점 곱셈을 shift 연산으로 대체하여 하드웨어 효율성이 우수하다. 그러나, 양자화 level이 평균값 근처에 과도하게 집중되는 rigid resolution으로 인해 정확도 하락이 심해지는 한계점이 존재한다 [6]. 이를 보정하기 위해 스케일 팩터에 APoT 구조를 차용하여 여러 개의 PoT 항의 합으로 근사하여 정확한 표현이 가능하도록 한다. 이때, 근사화된 스케일 팩터 $\hat{s}_{ap}$ 는 다음과 같이 정의된다:

$$\hat{s}_{ap} = \sum_{i=1}^N 2^{-k_i}, k_i \in \mathbb{N} \quad (8)$$

(8)에서 N 은 사용하는 항의 개수, k_i 는 i 번째 shift 항의 지수값이다. greedy 방식으로 s_f 에 근접한 PoT 조합을 구성해 정밀도 손실을 최소화하면서도, 곱셈 없이 shift-add 연산만으로 fused 양자화를 구현한다.

IV. 실험 결과

본 논문은 NVIDIA RTX 2080 Ti GPU 환경에서 PyTorch 프레임워크 기반 MobileNetV1 SSD Lite 모델과 범용 객체탐지 데이터셋인 Pascal VOC [8]을 활용하여 실험하였다.

표 1. 양자화 방법에 따른 MobileNetV1 SSD Lite 성능 비교 (Pascal VOC)

Method	Prec. (W/A)	mAP (%)	Drop (%)	Multiplier
Baseline	32/32	64.01	0.00	O
Uniform	8/8	63.10	0.91	O
PoT	8/8	51.24	12.77	X
Ours	8/8	63.27	0.74	X

제안한 APoT 기반 fused 양자화 기법의 효과를 검증하기 위해 일반적인 uniform 양자화와 단일 PoT 기반 양자화와의 성능 비교 실험을 수행하였다. 성능 평가지표로는 mean Average Precision (mAP), 모델 파라미터 수, 곱셈기 유무에 따른 연산효율성을 기준으로 삼았다.

표 1에서 Baseline은 full-precision 모델을 나타내며, 제안 기법 Ours는 Baseline대비 0.74% 정확도 손실이 있었다. 또한, uniform 양자화 대비 0.17%, 단일 PoT 기반에 비해 12.03%의 성능 향상을 달성하였다. 연산 측면에서는 곱셈기 없이 shift-add 연산으로 inference가 가능하며 이는 엣지 환경에서의 연산 효율 및 전력 소모에 있어 큰 이점을 가진다. 결과적으로, 우리는 단일 PoT의 rigid resolution으로 인해 발생하는 정확도 하락 문제를 효과적으로 해결하였으며, 하드웨어 친화적인 shift 연산 만으로 양자화 연산을 구현하였다.

V. 결론 및 향후 연구 방향

본 논문에서는 객체 탐지 모델에서 연산 효율성과 정확도를 동시에 확보하기 위해, APoT 구조를 차용한 fused 양자화 기법을 제안하였다. 결과적으로, 제안하는 방법은 기존의 uniform 및 PoT 단일 기반 양자화 기법에 비해 정확도 손실을 줄이면서도, 하드웨어 친화적인 구조를 유지할 수 있음을 확인하였다. 향후 연구에서 실제 FPGA 보드에서 설계를 통해 전력 소모, 처리 지연 등을 종합적으로 평가한다면 제안 기법의 실효성을 보다 정량적으로 검증할 수 있을 것이다.

감사의 글

이 논문은 과학기술정보통신부 및 정보통신기획평가원의 대학ICT연구센터육성지원사업의 연구결과(IITP-2025-RS-2022-00156295)와 2025년 산업통상자원부, 한국산업기술기술평가원(KEIT) 및 한국반도체 연구조합 지원 사업인 민관공동투자반도체 고급인력양성사업(RS-2025-02305531)으로 수행되었습니다.

참고문헌

- [1] J. Choi, D. Chun, H. Kim, and H.-J. Lee, "Gaussian yolov3: An accurate and fast object detector using localization uncertainty for autonomous driving," in *Proceedings of the IEEE/CVF International Conference on Computer Vision*, 2019, pp. 502–511.
- [2] S. Lee, and H. Kim, "Gaussianmask: Uncertainty-aware instance segmentation based on gaussian modeling." *2022 26th International Conference on Pattern Recognition (ICPR)*. IEEE, 2022.
- [3] B. Kang, D. Choi, and H. Kim, "Mixed precision quantization with hardware-friendly activation functions for hybrid ViT models." *2024 International Conference on Electronics, Information, and Communication (ICEIC)*. IEEE, 2024.
- [4] W. Liu, D. Anguelov, D. Erhan, C. Szegedy, S. Reed, C.-Y. Fu, and A. C. Berg, "Ssd: Single shot multibox detector." *Computer Vision—ECCV 2016: 14th European Conference, Amsterdam, The Netherlands, October 11–14, 2016, Proceedings, Part I 14*. Springer International Publishing, 2016.
- [5] D. Choi, J. Park, and H. Kim, "HLQ: Hardware-Friendly Logarithmic Quantization Aware Training for Power-Efficient Low-Precision CNN Models." *IEEE Access* (2024).
- [6] Y. Li, X. Dong, and W. Wang, "Additive powers-of-two quantization: An efficient non-uniform discretization for neural networks." *arXiv preprint arXiv:1909.13144* (2019).
- [7] N. Kim, J. Lee, and H. Kim, "HyQ: hardware-friendly post-training quantization for CNN-transformer hybrid networks." *Proceedings of the Thirty-Third International Joint Conference on Artificial Intelligence*. 2024.
- [8] M. Everingham, L. Van Gool, C. K. I. Williams, J. Winn, and A. Zisserman, "The pascal visual object classes (voc) challenge." *International journal of computer vision* 88 (2010): 303–338.