

하드웨어 친화적인 Power-of-Two 스케일 팩터 기반 MobilenetV1 SSD Lite 양자화

Dongjun Lee, Beomjin Kang, and Hyun Kim
Seoul National University of Science and Technology



Motivation

- 최근 **convolutional neural networks**는 컴퓨터 비전 분야에서 우수한 성능을 달성하였으나, **모델의 크기** 및 **연산량 증가** 문제 발생
- 모델 크기 증가는 메모리, 연산 능력, 전력 등이 제한된 **엣지 디바이스**에서 저전력·실시간 **추론에 큰 제약**으로 작용
- 메모리 문제를 해결하기 위해 **모델 경량화 기법**의 도입이 필수적이며, **양자화**가 대표적인 기법으로 주목받고 있음
- 일반적인 양자화는 정수-실수 변환의 반복으로 **연산 오버헤드** 발생, 오프라인에서 미리 스케일 팩터를 통합하는 fused 양자화 도입
- 양자화에서 사용되는 부동 소수점 곱셈 연산은 하드웨어 관점에서 상대적으로 큰 비용을 요구하기 때문에, 스케일 팩터를 Power-of-Two(PoT) 형태로 근사하여 부동 소수점 곱셈 연산을 **shift 연산으로 대체**
- 일반적인 PoT 근사화는 **표현 가능한 값의 한계** 존재해 근사화 오차가 발생하고 이로 인한 정확도 저하 발생

Proposed Method

APoT 기반 Fused 양자화

- PoT 기반 양자화의 한계**
 - Fig. 1.에서 PoT 기반 근사 경우 **표현 가능한 범위에 한계**가 존재
 - 특히 0.2 이상 범위에서 근사화 오차가 매우 커짐
- Additive Power-of-Two(APoT) 기반 fused 양자화**
 - APoT 구조[1] 기반으로 fused 스케일 팩터를 여러 PoT 항의 합으로 근사
 - 오프라인에서 Greedy 알고리즘을 사용하여 fused 스케일 팩터에 가장 근접하는 **최적의 PoT항 조합** 선택
 - 단일 PoT 근사 대비 높은 정밀도를 유지하면서도, **부동 소수점 곱셈기** 없이 **shift-add 연산만으로 구현**이 가능하여 **하드웨어 효율성** 확보

$$S_{apot} = \sum_{i=1}^T 2^{-k_i}, \quad \text{where } T \leq B, k_i \in 1, 2, \dots, k \quad (5)$$

S_{apot} : APoT 근사 적용한 스케일 팩터, T : 실제 사용한 PoT 항 개수, B : 최대 PoT항 개수, k : 최대 지수 범위

[1] Y. Li, X. Dong, and W. Wang, "Additive powers-of-two quantization: An efficient nonuniform discretization for neural networks," arXiv preprint arXiv:1909.13144 (2019)

Experimental Results

- 실험 환경**
 - NVIDIA RTX 2080 Ti x 8 GPU 환경
 - PyTorch 기반 MobileNetV1 SSD lite 모델 및 Pascal VOC Dataset을 사용하여 학습 및 추론
- Method**
 - Baseline**: 양자화 적용하지 않은 일반 모델 추론 결과
 - Uniform**: min/max 방법으로 양자화된 모델 추론 결과
 - PoT**: 단일 PoT 스케일 팩터 근사 기반으로 양자화된 모델 추론 결과
 - Ours**: APoT 스케일 팩터 근사 기반으로 양자화된 모델 추론 결과
- 분석**
 - Ours**는 **Baseline** 대비 **0.74%**의 mAP 하락을 보여, **0.91%** 하락한 **Uniform** 대비 우수한 수준
 - PoT**는 **12.77%**의 심각한 정확도 하락을 보이는 반면, **Ours**는 정확도 저하 문제 해결 및 **곱셈기 없는 fused 양자화** 구현
 - 정확도를 유지하면서도 **하드웨어 효율성**을 확보

Background

- 양자화**
 - 부동소수점 데이터를 낮은 bit의 정수 데이터로 **양자화(1)**하여 연산 후 **역양자화(2)**를 통해 복원
- $$a_{i,dq} = S_{i,x}S_{i,w} \cdot a_{i,q} \quad (1), \quad x_{i+1,q} = Q\left(\frac{a_{i,dq}}{S_{i+1,x}}\right) \quad (2)$$
- x : 입력 값, a : 출력 값, S : 스케일 팩터, $Q(x)$: 양자화
- Fused 양자화**
 - 연속되는 레이어 간 역양자화-양자화 과정에서 사용되는 **스케일 팩터를 하나로 통합**하여 중간 단계 실수 연산을 제거
- $$x_{i+1,q} = Q\left(\frac{S_{i,x}S_{i,w}}{S_{i+1,x}} \cdot a_{i,q}\right) = Q(S_f \cdot a_{i,q}), \quad \text{where } S_f = \frac{S_{i,x}S_{i,w}}{S_{i+1,x}} \quad (3)$$
- S_f : 통합된 fused 스케일 팩터
- PoT 기반 fused 양자화**
 - Fused 양자화에서 사용되는 스케일 팩터를 2^{-k} 형태로 근사하여 부동 소수점 곱셈 연산을 **shift 연산으로 대체**
- $$\hat{x}_{i+1,q} = Q(a_{i,q} \gg k), \quad \text{where } S_f \approx 2^{-k} = S_{pot} \quad (4)$$
- $\hat{x}$: PoT 근사 양자화 적용된 입력, $\gg$: shift 연산, S_{pot} : PoT 근사화 된 스케일 팩터

PoT와 APoT 정밀도 비교




Fig. 1. PoT 기반 근사화 APoT 기반 근사화의 표현 정밀도 차이, (a) 0~1범위, (b) 0~0.1 범위

Method	Prec.(W/A)	mAP (%)	Drop (%)	Multiplier
Baseline	32 / 32	64.01	0.00	O
Uniform	8 / 8	63.10	0.91	O
PoT	8 / 8	51.24	12.77	X
Ours	8 / 8	63.27	0.74	X

Table 1. 양자화 precision에 따른 SSD 실험 결과

- 결론**
 - 엣지 디바이스에서 저전력·실시간 추론을 위해 **양자화 필요**
 - 제안하는 APoT기반 fused 양자화는 단일 PoT 방법의 **정확도 보완**과 **하드웨어 효율성**을 동시에 만족하는 **효과적인 경량화 기법**