

MoE 모델의 초저비트 양자화를 위한 Gating-Weighted Expert Scale 보정 기법

이동준, 구광현, 김현

서울과학기술대학교 전기정보공학과 전기정보기술연구소

e-mail : {dj.lee, kookh0414, hyunkim}@seoultech.ac.kr

Gating-Weighted Expert Scale Correction for Ultra-Low-Bit Quantization of MoE Models

Dongjun Lee, Kwanghyun Koo, Hyun Kim

Depart. of EIE and Research Center for Electrical and Information Technology,
Seoul National University of Science and Technology

Abstract

This paper proposes gating-weighted expert scale correction (GESc) to mitigate expert-wise output errors and activation shifts that occur in 2-bit quantization of MoE models. When existing quantization methods are applied to MoE models, they may not sufficiently reflect the routing structure and differences in expert-wise output contribution, which can lead to performance degradation. The proposed method computes and applies an expert-wise scale factor by using the gating score as a weight in the loss. This scale factor is pre-applied to the quantized weight, allowing activation shift to be corrected without additional inference overhead. Experimental results on Qwen2-MoE-57B and DeepSeek-V2-Lite show that the proposed method achieves lower perplexity and higher zero-shot accuracy than the conventional E8-lattice VQ.

I. 서론

최근 Transformer 기반 large language model (LLM)은 다양한 자연어 처리 task에서 높은 성능을 보이며 주목받고 있다 [1]. 그러나 성능 향상을 위해

모델 규모가 커질수록 연산량과 메모리 요구량이 함께 증가하여 실제 배포에 큰 제약이 발생한다[2], [3]. 이를 완화하기 위해 입력 token마다 일부 expert만 선택적으로 활성화하는 mixture-of-experts (MoE) 구조가 도입되었다[4]. MoE는 실제 연산량의 증가는 제한적이면서도 전체 모델 용량을 확장하는 구조로 각광받고 있다[5]. 하지만 모든 expert의 파라미터를 메모리에 저장해야 하므로 단일 GPU 또는 엣지 디바이스와 같은 메모리 제약 환경에서는 배포가 어렵다[6].

MoE 모델의 메모리 부담을 줄이기 위해 양자화 가지치기 등 다양한 경량화 기법이 연구되고 있다[2]. 그중 양자화는 weight를 낮은 bit-width로 표현하여 모델 크기와 메모리 접근량을 줄이는 대표적인 방법이다[7]. 특히 여러 weight를 하나의 vector로 묶어 codebook으로 표현하는 vector quantization (VQ)은 안정적인 성능을 달성하였다[8]. 그러나 기존 양자화 기법을 MoE 모델에 적용하는 경우 특정 expert에서 발생한 양자화 오차가 후속 layer로 전달되며 activation 분포 변화를 유발할 수 있다[9].

이에 본 논문에서는 gating network의 출력값을 loss의 가중치로 사용하여 양자화 오차를 보정하는 gating-weighted expert scale correction (GESc) 기법을 제안한다. 실험 결과 제안 방법은 2-bit 환경에서 기존 E8-lattice VQ 대비 낮은 perplexity와 높은 zero-shot accuracy를 달성하였다.

II. 배경

2.1 MoE 기반 LLM

MoE 구조는 dense LLM의 feed-forward network (FFN)를 여러 개의 expert로 확장한 구조이다. Dense LLM에서는 모든 token이 동일한 FFN을 통과한다. 반면 MoE 모델은 gating network를 통해 입력 token에 적합한 일부 expert만 선택적으로 활성화한다. 이때 gating network는 각 expert에 대한 score를 계산하며, 일반적으로 score가 높은 top-k expert가 선택된다.

선택된 expert의 출력은 gating score를 가중치로 사용하여 합산된다. 따라서 MoE layer의 출력은 token별 routing 결과가 반영된 가중합으로 계산된다. 이러한 sparse activation 구조는 전체 모델 용량을 확장하면서도 실제 활성화되는 연산량을 제한할 수 있다는 장점이 있다. 그러나 추론 시 선택되지 않는 expert의 weight도 메모리에 저장해야 하므로, expert 수가 증가할수록 전체 메모리 사용량이 크게 증가한다. 따라서 MoE 모델을 메모리 제약 환경에 배포하기 위해서는 전체 파라미터에서 큰 비중을 차지하는 expert weight를 대상으로 한 초저비트 환경의 경량화가 필요하다.

2.2 MoE 모델에서의 양자화 오차 누적 문제

MoE 모델에서는 token마다 선택되는 expert가 다르고, expert별 선택 빈도와 출력 기여도도 서로 다르다. 또한 MoE layer의 출력은 선택된 expert 출력이 gating score에 따라 가중합되는 구조이기 때문에, 동일한 크기의 양자화 오차라도 모든 expert에 동일한 영향으로 작용하지 않는다.

그림 1은 E8-lattice VQ를 적용했을 때 layer별 activation 분포를 FP16과 비교한 결과이다. 초기 layer인 layer 0에서는 FP16과 E8-lattice VQ의 activation 분포가 거의 유사하게 나타난다. 반면 후반 layer인 layer 32에서는 E8-lattice VQ의 activation 분포가 FP16 대비 넓게 퍼지며, 분포의 형태도 뚜렷하게 달라지는 것을 확인할 수 있다. 이는 앞선 layer에서 발생한 양자화 오차가 이후 layer의 입력 activation으로 전달되면서, layer가 깊어질수록 activation 분포 변화가 누적될 수 있음을 보여준다. 특히 2-bit와 같은 초저비트 환경에서는 weight 표현력이 제한되므로 이러한 분포 변화가 성능 저하로 이어질 가능성이 크다. 따라서 MoE 모델의 초저비트 양자화에서는 routing 구조를 반영하여 실제 출력에 크게 기여하는 expert의 오차를 줄이는 보정이 필요하다.




그림 1. MoE 모델의 layer별 activation 분포 변화

III. 구현

3.1 E8-lattice 기반 양자화

본 논문에서는 QuIP# [8]에서 사용된 random Hadamard transform 기반 E8-lattice VQ를 기본 양자화 방법으로 사용한다. Random Hadamard transform은 weight에 random sign flip과 Hadamard transform을 적용하여 특정 좌표에 집중된 outlier 영향을 완화한다. 이를 통해 weight 값이 일부 outlier에 과도하게 영향을 받지 않고, E8-lattice codebook으로 양자화하기에 적합한 분포를 갖도록 한다.

변환된 weight는 8차원 vector 단위로 분할된다. 이후 각 vector는 E8-lattice codebook에 포함된 codeword 중 가장 가까운 값으로 치환된다. E8-lattice는 8차원 공간에서 효율적인 packing 구조를 가지므로, 2-bit와 같은 초저비트 환경에서도 vector 단위의 표현력을 확보할 수 있다. 본 논문에서는 모든 expert에 동일한 E8-lattice VQ를 적용하고, 이후 GESC를 통해 MoE 구조에서 발생하는 activation 분포 변화를 보정한다.

3.2 gating-weighted expert scale correction

GESC는 calibration data를 이용해 full-precision expert output과 quantized expert output의 차이를 계산하고, gating score를 loss의 가중치로 사용하여 expert별 scale factor를 계산한다. 입력 token t 에 대한 expert e 의 full-precision output을 $y_{t,e}$, quantized output을 $\hat{y}_{t,e}$, gating score를 $g_{t,e}$ 라고 할 때, expert별 scale factor s_e 는 다음 loss $\mathcal{L}_e$ 를 최소화하도록 계산된다.

$$\mathcal{L}_e = \sum_{t=1}^T g_{t,e} \|y_{t,e} - s_e \hat{y}_{t,e}\|_2^2 \quad (1)$$

여기서 T 는 calibration token 수를 의미한다. 일반적인 reconstruction loss는 모든 token의 오차를 동일하게 반영한다. 반면 제안하는 loss는 gating score가 큰 token-expert 조합의 오차를 더 크게 반영한다. 따라서 실제 MoE 출력에 더 크게 기여하는 expert의 양자화 오차를 우선적으로 보정할 수 있다.

위 loss는 least-squares 형태이므로, expert별 최적 scale factor s_e^* 는 다음과 같이 계산된다.

$$s_e^* = \frac{\sum_{t=1}^T g_{t,e} y_{t,e}^T y_{t,e}}{\sum_{t=1}^T g_{t,e} y_{t,e}^T y_{t,e}} \quad (2)$$

또한 계산된 s_e^* 는 추론 과정에서 별도의 연산으로 적용하지 않고, 양자화된 expert weight $\tilde{W}_e$ 에 미리 반영한다.

$$\tilde{W}_e = s_e^* W_e, \tilde{y}_{t,e} = \tilde{W}_e x_t \quad (3)$$

여기서 $\tilde{W}_e$ 는 scale factor가 반영된 expert weight, $\tilde{y}_{t,e}$ 는 $\tilde{W}_e$ 를 통해 계산된 expert output이다. 이를 통해 실제 추론에서는 추가적인 연산 없이 보정이 가능하다.

IV. 실험 결과

4.1 실험 세팅

제안하는 GESC의 효과를 검증하기 위해 범용 오픈 소스 MoE 모델인 Qwen2-MoE-57B와 DeepSeek-V2-Lite를 대상으로 실험을 수행하였다. 실험은 NVIDIA A100 GPU 2장 환경에서 진행하였으며, PyTorch 기반으로 구현된 양자화 및 평가 코드를 사용하였다. DeepSeek-V2-Lite의 첫 번째 layer는 MoE block이 아닌 dense FFN 구조로, 해당 layer는 양자화 대상에서 제외하였다.

Calibration은 WikiText2 [10] train split에서 256개 sample을 사용하였으며, sequence length는 4096으로 설정하였다. Gating score는 expert별 평균값을 사용하였고, layer 내부 expert들의 gate weight 평균이 1이 되도록 정규화한 뒤 0.25에서 4.0 범위로 clipping하였다.

Perplexity (PPL) 평가는 WikiText2 [10] test split에서 sequence length 4096으로 수행하였다. Zero-shot 평가는 lm-evaluation-harness의 HFLM backend를 사용하였으며 [11], ARC-Challenge, ARC-Easy, HellaSwag, LAMBADA-OpenAI, LAMBADA-Standard, PIQA, WinoGrande 총 7개 task를 대상으로 수행하였다. 최종 zero-shot accuracy는 7개 task의 단순 평균으로 계산하였다.

4.2 실험 결과

표 1은 양자화 방법에 따른 MoE 모델의 성능 비교 결과를 나타낸다. Baseline은 양자화를 적용하지 않은 모델을 의미하며, RTN은 round-to-nearest 방식으로 weight를 가장 가까운 양자화 값에 매핑한 결과이다. E8은 기존 E8-lattice VQ만 적용한 결과이고, Ours는 E8-lattice VQ 이후 제안하는 GESC를 적용한 결과이다. Prec.는 weight와 activation의 bit-width를 의미한다. PPL은 perplexity로 낮을수록 우

표 1. 양자화 방법에 따른 MoE 모델 성능 비교

Model	Method	Prec. (W/A)	PPL	z-shot acc.
Qwen2 MoE-57B	Baseline	16/16	5.84	72.53
	RTN	2/16	445454	26.2
	E8	2/16	10.29	65.18
	Ours	2/16	7.59	67.66
DeepSeek V2-Lite	Baseline	16/16	5.92	70.59
	RTN	2/16	15.43	46.71
	E8	2/16	9.03	61.69
	Ours	2/16	7.38	65.27

수하며, z-shot acc.는 7개 zero-shot task의 평균 accuracy로 높을수록 우수하다.

제안 방법은 두 모델 모두 2-bit 환경에서 기존 E8-lattice VQ 대비 성능을 개선하였다. Qwen2-MoE-57B의 경우, GESC는 기존 E8-lattice VQ 대비 PPL을 10.29에서 7.59로 2.70 낮추고, zero-shot accuracy를 65.18%에서 67.66%로 2.48%p 향상시켰다. DeepSeek-V2-Lite의 경우에도 PPL을 9.03에서 7.38로 1.65 낮추고, zero-shot accuracy를 61.69%에서 65.27%로 3.58%p 향상시켰다.

이러한 결과는 기존 E8-lattice VQ를 MoE 모델에 직접 적용하는 것만으로는 expert별 출력 오차를 충분히 보정하기 어렵다는 점을 보여준다. 반면 GESC는 gating score를 반영하여 실제 MoE 출력에 더 크게 기여하는 expert의 오차를 우선적으로 보정한다. 따라서 제안 방법은 2-bit 초저비트 양자화 환경에서 발생하는 activation shift를 완화하고, MoE 모델의 성능 저하를 줄이는 데 효과적임을 확인할 수 있다.

V. 결론 및 향후 연구 방향

본 논문에서는 MoE 모델의 초저비트 양자화에서 발생하는 expert별 출력 오차와 activation 분포 변화를 완화하기 위해 GESC를 제안하였다. 기존 E8-lattice VQ는 저비트 환경에서 우수한 표현력을 보이지만, MoE 모델의 routing 구조와 expert별 출력 기여도 차이를 직접적으로 반영하지 못한다. 이에 본 논문에서는 gating score를 loss의 가중치로 사용하여 실제 MoE 출력에 더 크게 기여하는 expert의 오차를 우선적으로 보정하였다.

제안 방법은 calibration data를 이용해 expert별 scale factor를 계산하고, 이를 양자화된 expert weight에 미리 반영한다. 따라서 추론 과정에서 추가적인 scale multiplication 없이 기존 E8-lattice VQ와 동일한 방식으로 연산할 수 있다. 실험 결과,

Qwen2-MoE-57B와 DeepSeek-V2-Lite의 2-bit 양자화 환경에서 제안 방법은 기존 E8-lattice VQ 대비 낮은 PPL과 높은 zero-shot accuracy를 달성하였다. 이를 통해 GESC가 MoE 모델의 초저비트 양자화에서 activation 분포 변화를 완화하고 성능 저하를 줄이는 데 효과적임을 확인하였다.

향후 연구에서는 expert별 단일 scale factor를 channel-wise scale 보정으로 확장함으로써, 보다 세밀한 출력 분포 보정과 안정적인 성능 개선 가능성을 분석할 예정이다.

감사의 글

This research was partly supported by Basic Science Research Program through the National Research Foundation of Korea(NRF) funded by the Ministry of Education(RS-2019-NR040071 and RS-2025-25429747).

참고문헌

- [1] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, Ł. Kaiser, and I. Polosukhin, "Attention is all you need," in *Advances in Neural Information Processing Systems*, vol. 30, 2017.
- [2] G. Lee, S. Kim, D. Lee, K. Goh, and H. Kim, "Towards Efficient Language Giants: A Comprehensive Survey on Structural Optimizations and Compression Techniques for Large Language Models," *Neural Networks*, vol. 201, pp. 108900–108925, 2026.
- [3] Y. Kim, S. Yoon, S. Han, C. Park, J. Park, J. Ko, and H. Kim, "Accelerating Language Giants: A Survey of Optimization Strategies for LLM Inference on Hardware Platforms," *Journal of Systems Architecture*, vol. 172, pp. 103690–103708, 2026.
- [4] A. Q. Jiang, A. Sablayrolles, A. Roux, A. Mensch, B. Savary, C. Bamford, D. S. Chaplot, D. de las Casas, E. B. Hanna, F. Bressand, et al., "Mixtral of Experts," *arXiv preprint arXiv:2401.04088*, 2024.
- [5] D. Dai, C. Deng, C. Zhao, R. Xu, H. Gao, D. Chen, J. Li, W. Zeng, X. Yu, Y. Wu, et al., "DeepSeekMoE: Towards Ultimate Expert Specialization in Mixture-of-Experts Language Models," *arXiv preprint arXiv:2401.06066*, 2024.
- [6] M. Ai, T. Wei, Y. Chen, Z. Zeng, R. Zhao, G. Varatkar, B. D. Rouhani, X. Tang, H. Tong, and J. He, "ResMoE: Space-Efficient Compression of Mixture of Experts LLMs via Residual Restoration," in *Proceedings of the 31st ACM SIGKDD Conference on Knowledge Discovery and Data Mining*, 2025, pp. 1–12.
- [7] N. Kim, J. Lee, and H. Kim, "HyQ: hardware-friendly post-training quantization for CNN-transformer hybrid networks." *Proceedings of the Thirty-Third International Joint Conference on Artificial Intelligence*. 2024.
- [8] A. Tseng, J. Chee, Q. Sun, V. Kuleshov, and C. De Sa, "QuIP#: Even Better LLM Quantization with Hadamard Incoherence and Lattice Codebooks," in *International Conference on Machine Learning*, 2024.
- [9] Z. Xu, Z. Zhao, X. Hu, Z. Chen, and D. Yang, "KBVQ-MoE: KLT-Guided SVD with Bias-Corrected Vector Quantization for MoE Large Language Models," in *International Conference on Learning Representations*, 2026.
- [10] S. Merity, C. Xiong, J. Bradbury, and R. Socher, "Pointer Sentinel Mixture Models," in *International Conference on Learning Representations*, 2017.
- [11] L. Gao, J. Tow, B. Abbasi, S. Biderman, S. Black, A. DiPofi, C. Foster, L. Golding, J. Hsu, K. McDonnell, et al., "A Framework for Few-shot Language Model Evaluation," *Zenodo*, 2024.