

MoE 모델의 초저비트 양자화를 위한 Gating-Weighted Expert Scale 보정 기법

Dongjun Lee, Kwanghyun Koo, and Hyun Kim
Seoul National University of Science and Technology



Motivation

- Large language model (LLM)은 다양한 자연어 처리 task에서 우수한 성능을 달성하였으나, 모델 규모 증가에 따른 **연산량 및 메모리 요구량 증가** 문제 발생
- Mixture-of-experts (MoE) 모델은 여러 expert 중 일부 expert만 활성화하여 연산량 증가를 제한하면서 **모델 용량을 효과적으로 확장**
- MoE 모델은 추론 시 모든 expert weight를 메모리에 저장해야 하므로, 엣지 또는 Single-GPU와 같은 **메모리 제약 환경에서 배포에 큰 제약** 발생
- MoE 모델의 메모리 부담을 줄이기 위해 expert weight를 낮은 bit-width로 표현하는 **초저비트 양자화 필요**
- 기존 양자화 기법은 Fig. 1과 같이 MoE 모델의 routing 구조와 expert별 출력 기여도 차이를 반영하지 못해 **양자화 오차가 누적**될 수 있음
- MoE 모델의 초저비트 양자화에서 발생하는 양자화 오차를 완화하기 위해 **gating-aware** expert scale 보정 기법 필요

Proposed Method

- Vector Quantization (VQ)**
 - 기존 random Hadamard transform (RHT) 기반 lattice VQ [1]을 기반으로 MoE expert 양자화
 - RHT를 통해 weight outlier의 영향을 완화하고, 8차원 vector 단위로 E8-lattice codebook 내 가장 가까운 codeword로 치환하여 **2-bit 수준의 expert weight 표현** 생성
- Gating-Weighted Expert Scale Correction (GESC)**
 - Calibration 토큰 T 개를 이용해 down-projection layer의 full-precision expert output $E_e(x_t)$ 과 quantized expert output $\hat{E}_e(x_t)$ 간의 오차 측정
 - Gating score 기반 weighted loss를 최소화하도록 expert별 scale factor s_e^* 계산
 - 계산된 scale factor를 quantized expert weight $\hat{W}_e$ 에 사전 반영하여 **추가 오버헤드 없이 보정**

$$s_e^* = \arg \min_{s_e} \sum_{t=1}^T G_e(x_t) \|E_e(x_t) - s_e \hat{E}_e(x_t)\|_2^2, \quad \tilde{W}_e = s_e^* \hat{W}_e \quad (2)$$

[1] Tseng, Albert, et al. "Quip#: Even better llm quantization with hadamard incoherence and lattice codebooks." Proceedings of machine learning research 235 (2024): 48630.

Experimental Results

- 실험 환경**
 - NVIDIA A100 GPU×2 환경에서 PyTorch 기반 weight-only 양자화 및 평가 코드 구현
 - 대표적인 MoE 모델 Qwen2-MoE-57B와 DeepSeek-V2-Lite에서 WikiText2 perplexity(PPL)와 7개 zero-shot(Z-shot) task 평균 accuracy 평가
- 결과 분석**
 - Baseline은 FP16 모델, RTN은 round-to-nearest 양자화, E8은 lattice VQ, Ours는 GESG 결과
 - Qwen2-MoE-57B에서 Ours는 E8 대비 PPL **2.70 감소**, Z-shot accuracy 평균 **2.48%p 향상**
 - DeepSeek-V2-Lite에서 Ours는 E8 대비 PPL **1.65 감소**, Z-shot accuracy 평균 **3.58%p 향상**
- 결론**
 - 기존 양자화 기법은 MoE의 expert별 출력 기여도 차이를 반영하지 못해 성능 저하 발생
 - GESG는 gating score 기반 expert-wise scale 보정 값을 quantized weight에 사전 반영하여, 추가적인 **inference 오버헤드 없이** MoE 모델의 **초저비트 양자화 성능 개선**

Background

- MoE 기반 LLM**
 - MoE 모델은 dense LLM의 feed-forward network (FFN)를 여러 expert로 확장한 구조
 - 입력 토큰 x_t 는 gating network를 통해 각 expert의 gating score $G_e(x_t)$ 를 계산하고, score가 높은 **top-k expert만 활성화**
 - 선택된 expert 집합 $\mathcal{E}_t$ 내 각 expert e 의 출력 $E_e(x_t)$ 는 gating score 기반 weighted sum으로 최종 output y_t 생성

$$y_t = \sum_{e \in \mathcal{E}_t} G_e(x_t) E_e(x_t) \quad (1)$$

- MoE 모델에서의 양자화 오차 누적 문제**
 - MoE 모델은 각 입력 토큰마다 선택되는 expert와 gating score가 달라, expert별 양자화 오차가 최종 output에 미치는 영향도 달라짐
 - 기존 양자화 기법은 expert 양자화 오차를 효과적으로 보정하기 어려우며, Fig. 2와 같이 layer가 깊어질수록 **activation 분포 변화가 누적**될 수 있음




Fig. 1. Expert별 local loss와 routing-weighted loss 비교




Fig. 2. MoE 모델의 layer별 activation 분포 변화

Model	Method	Precision	PPL (↓)	Z-shot Acc. Avg. (↑)
Qwen2 MoE-57B	Baseline	W16/A16	5.84	72.53%
	RTN	W2/A16	4.45e+5	26.2%
	E8	W2/A16	10.29	65.18%
	Ours	W2/A16	7.59	67.66%
DeepSeek V2-Lite	Baseline	W16/A16	5.92	70.59%
	RTN	W2/A16	15.43	46.71%
	E8	W2/A16	9.03	61.69%
	Ours	W2/A16	7.38	65.27%

Table 1. 양자화 기법에 따른 perplexity 및 zero-shot accuracy 결과